



I302 - Aprendizaje Automático y Aprendizaje Profundo

Trabajo Práctico 4: Aprendizaje No-Supervisado

Santino Cardelli

9 de junio de 2026

Ingeniería en Inteligencia Artificial

Resumen

En este trabajo se exploraron técnicas de aprendizaje no supervisado sobre un subconjunto de Fashion-MNIST (25.000 imágenes de 28×28 píxeles, 10 clases balanceadas). Se implementaron desde cero los algoritmos de reducción de dimensionalidad y clustering. Primero se redujo la dimensionalidad mediante PCA (reteniendo 134 componentes para explicar el 90 % de la varianza) y mediante un Autoencoder determinístico con idéntica dimensión latente, comparándose la calidad de sus reconstrucciones. Además, se entrenó un β -VAE, cuyo espacio latente regularizado demostró capacidad generativa, a diferencia del AE determinístico. Luego, sobre los espacios latentes de PCA y AE se aplicaron K-Means y un *Gaussian Mixture Model* (GMM) entrenado con *Expectation-Maximization*, seleccionando el número de clusters K mediante el método de ganancias decrecientes y el *Silhouette score*. El espacio de PCA sugirió $K \approx 9-10$, cercano a las 10 clases reales, mientras que el del Autoencoder tendió a $K \approx 6$. Finalmente, se utilizó t-SNE para visualizar los clusters en 2 dimensiones, evidenciando que las clases visualmente distintivas (calzado, pantalón, cartera) se agrupan con alta homogeneidad, mientras que las prendas de torso se confunden entre sí.

1. Introducción

El objetivo del trabajo es desarrollar y evaluar métodos de aprendizaje no supervisado sobre un conjunto de imágenes. La entrada del problema son imágenes en escala de grises de 28×28 píxeles (vectores de 784 dimensiones) provenientes del dataset `fashion_mnist_subset.csv`, que contiene 25.000 muestras pertenecientes a 10 categorías de indumentaria y calzado.

A diferencia de un problema supervisado, aquí las etiquetas de clase no se utilizan para entrenar los modelos, sino únicamente como referencia (*ground truth*) para evaluar a posteriori la calidad de las estructuras descubiertas. El trabajo se organiza en tres etapas. En la primera, se reduce la dimensionalidad de las imágenes mediante dos técnicas: *Principal Component Analysis* (PCA), de naturaleza lineal, y un Autoencoder (AE) determinístico, capaz de capturar relaciones no lineales. En la segunda, se aplican dos algoritmos de *clustering* (K-Means y GMM) sobre los espacios latentes obtenidos, con el fin de agrupar las imágenes sin conocer sus etiquetas. En la tercera, se visualiza la estructura de los clusters en dos dimensiones mediante t-SNE y se analiza su calidad.

2. Métodos

2.1. Conjunto de datos y preprocesamiento

El dataset cuenta con 25.000 imágenes perfectamente balanceadas: exactamente 2.500 muestras por cada una de las 10 clases (Figura 1a). Esta uniformidad evita la necesidad de técnicas de remuestreo o de corrección de sesgos hacia clases mayoritarias. Se realizó un split estratificado 80/20, conformando un conjunto de entrenamiento de 20.000 muestras y uno de validación de 5.000, preservando la proporción del 10 % de cada clase en ambos conjuntos.

Como preprocesamiento se aplicó estandarización: a cada píxel se le restó la media y se lo dividió por el desvío estándar calculados *únicamente* sobre el conjunto de entrenamiento, $z = (x - \mu_{\text{train}}) / \sigma_{\text{train}}$. La media y el desvío del entrenamiento se reutilizaron luego para estandarizar el conjunto de validación, evitando así *data leakage*.

2.2. Reducción de dimensionalidad

PCA: PCA busca una base ortonormal de *componentes principales* que maximizan la varianza capturada en cada dirección. La implementación se basó en la descomposición en valores singulares (SVD) de la matriz de datos estandarizada $X = U\Sigma V^\top$, donde las columnas de V son las componentes principales y los valores singulares al cuadrado son proporcionales a la varianza explicada por cada una. La proyección a k dimensiones se obtiene como $Z = XV_k$, y la reconstrucción como $\hat{X} = ZV_k^\top$ (deshaciendo luego la estandarización). El número de componentes k se eligió como el mínimo que asegura explicar el 90 % de la varianza acumulada.

Autoencoder (AE): Un autoencoder es una red neuronal que aprende a comprimir y reconstruir sus entradas. Consta de un *encoder* $f_\theta : \mathbb{R}^{784} \rightarrow \mathbb{R}^k$ que mapea la imagen a un espacio latente, y un *decoder* $g_\phi : \mathbb{R}^k \rightarrow \mathbb{R}^{784}$ que la reconstruye. Se entrena minimizando el error de reconstrucción, en este caso el error cuadrático medio (MSE):

$$\mathcal{L}(\theta, \phi) = \frac{1}{N} \sum_{i=1}^N \|x_i - g_\phi(f_\theta(x_i))\|_2^2. \quad (1)$$

La arquitectura empleada es simétrica: el encoder consta de capas densas $784 \rightarrow 512 \rightarrow 256 \rightarrow k$ y el decoder las refleja ($k \rightarrow 256 \rightarrow 512 \rightarrow 784$), con activaciones **LeakyReLU** entre capas. Para una comparación justa con PCA, la dimensión latente se fijó en $k = 134$, idéntica a la cantidad de componentes retenidas por PCA.

Hiperparámetros del AE. Se utilizó el optimizador Adam con *learning rate* 10^{-3} , *batch size* de 512, una probabilidad de *dropout* de 0,01 como regularización leve, y un máximo de 300 épocas. Se aplicó **early stopping** con paciencia de 30 épocas, restaurando los pesos del mejor modelo según la pérdida de validación. Estos valores se ajustaron de forma iterativa observando la curva de aprendizaje, buscando una convergencia estable y sin sobreajuste.

β -Variational Autoencoder (β -VAE). También se implementó un β -VAE [1]. A diferencia del AE determinístico, que mapea cada entrada a un punto fijo del espacio latente, el VAE es un modelo *generativo*: el encoder produce los parámetros de una distribución $q_\phi(z|x) = \mathcal{N}(\mu, \sigma^2 I)$ y el vector latente se obtiene muestreando de ella mediante el *reparameterization trick*, $z = \mu + \sigma \odot \epsilon$ con $\epsilon \sim \mathcal{N}(0, I)$, que permite retropropagar a través de la operación estocástica. La pérdida combina un término de reconstrucción y uno de regularización, ponderado por un factor β :

$$\mathcal{L} = \underbrace{\mathbb{E}_{q_\phi(z|x)} [\|x - \hat{x}\|_2^2]}_{\text{reconstrucción (MSE)}} + \beta \cdot \underbrace{D_{KL}(q_\phi(z|x) \parallel \mathcal{N}(0, I))}_{\text{regularización}}. \quad (2)$$

El término de Kullback-Leibler empuja la distribución latente hacia un prior $\mathcal{N}(0, I)$, forzando un espacio latente continuo y estructurado. La diferencia con un VAE tradicional es el hiperparámetro β : con $\beta > 1$ se penaliza más fuertemente la divergencia respecto del prior, haciendo que el modelo genere mejores datos (a costa de cierta fidelidad de reconstrucción). Se utilizó la misma dimensión latente $k = 134$ y $\beta = 1,5$.

2.3. Clustering

Por razones de costo computacional, esta etapa se trabajó sobre una muestra estratificada de 3.000 puntos (300 por clase) de cada espacio latente.

K-Means. Particiona los datos en K grupos minimizando la inercia (suma de distancias cuadradas de cada punto a su centroide):

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2. \quad (3)$$

El algoritmo alterna entre asignar cada punto a su centroide más cercano y recalculando los centroides como la media de los puntos asignados. Para mitigar la sensibilidad a la inicialización, se ejecutó con 15 inicializaciones aleatorias distintas, conservando la de menor inercia.

Gaussian Mixture Model (GMM). Modela la densidad de los datos como una mezcla de K distribuciones gaussianas, $p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$, y se entrena con el algoritmo *Expectation-Maximization* (EM). En el paso E se calculan las responsabilidades (probabilidad posterior de que cada punto pertenezca a cada componente) y en el paso M se actualizan los pesos π_k , medias μ_k y covarianzas Σ_k . A diferencia de K-Means, GMM realiza una asignación *soft* y admite clusters elípticos de distinta forma. Para estabilizar la convergencia de EM (que es muy sensible a la inicialización) se inicializaron las medias con los centroides obtenidos por K-Means.

Selección de K y métricas. El número de clusters se exploró en el rango $[5, 15]$ mediante dos criterios complementarios:

- **Método de ganancias decrecientes:** se grafica la métrica de ajuste (inercia para K-Means; log-verosimilitud negativa, NLL, para GMM) y su *ganancia marginal* entre valores consecutivos de K . El “codo” señala el punto a partir del cual agregar clusters deja de aportar mejoras significativas.
- **Silhouette score:** para cada punto i se calcula $s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$, donde $a(i)$ es la distancia media intra-cluster y $b(i)$ la distancia media al cluster vecino más cercano. El valor global (promedio) está acotado en $[-1, 1]$, donde valores altos indican clusters bien separados.

t-SNE. Para la visualización final se implementó t-SNE, que proyecta los datos a 2D preservando la estructura local. El método modela las similitudes entre puntos en alta dimensión mediante probabilidades condicionales gaussianas, y en baja dimensión mediante una distribución t-Student. Minimiza la divergencia de Kullback-Leibler entre ambas distribuciones por descenso de gradiente.

3. Resultados

3.1. Análisis exploratorio

La distribución de clases (Figura 1a) confirmó el balance perfecto del dataset. Al graficar muestras agrupadas por clase se observó una notable variabilidad intra-clase: dentro de una misma categoría existen diferencias evidentes en diseño, textura, grosor y forma (Figura 2). Esta diversidad justifica el uso de técnicas de reducción de dimensionalidad que extraigan características latentes significativas, en lugar de depender únicamente de las similitudes a nivel de píxel.




Figura 1: Análisis exploratorio inicial del conjunto de datos Fashion-MNIST.



Figura 2: Variabilidad intra-clase para dos clases representativas.

3.2. Reducción de dimensionalidad

El análisis de la varianza explicada acumulada (Figura 3a) indicó que se requieren 134 componentes principales para alcanzar el umbral del 90 % de la información original, una reducción considerable desde las 784 dimensiones iniciales. Al reconstruir las imágenes desde este subespacio, se preserva la estructura general, la simetría y la silueta de las prendas (Figura 3b). No obstante, la compresión conlleva una pérdida natural de información. Esto hace que los detalles finos, las texturas complejas y los bordes definidos se suavizan, produciendo un efecto de difuminado.

El Autoencoder, entrenado con idéntica dimensión latente ($k = 134$), exhibió una curva de aprendizaje estable y convergente (Figura 4). A lo largo de 262 épocas (hasta la activación del early stopping) se observó un descenso suave y continuo de ambas pérdidas, manteniendo




Figura 3: Resultados de PCA sobre el conjunto de validación.

una brecha mínima entre entrenamiento y validación, lo que indica ausencia de overfitting. La pérdida de validación mínima retenida fue de 0,1018.

Al comparar las reconstrucciones de ambos métodos sobre las mismas 10 imágenes (ver Figura 6, que las muestra junto al β -VAE), se aprecia que tanto PCA como el AE preservan la estructura general de las prendas. Sin embargo, la naturaleza de cada algoritmo introduce diferencias visuales: PCA, limitado a proyecciones lineales, genera reconstrucciones con difuminado generalizado y ruido residual en el fondo oscuro. El Autoencoder, gracias a sus activaciones no lineales, produce fondos más limpios y bordes ligeramente más definidos. Si bien ambos métodos pierden información de alta frecuencia (como estampados complejos), el AE demuestra mayor capacidad para aislar el objeto de interés y mitigar el ruido de fondo.




Figura 4: Curva de aprendizaje del Autoencoder determinístico. La pérdida de validación mínima retenida fue de 0,1018.




Figura 5: Curvas de aprendizaje del β -VAE, separando la pérdida total, la de reconstrucción (MSE) y la divergencia KL.

3.3. β -VAE

Las curvas de aprendizaje del β -VAE (Figura 5) muestran un entrenamiento estable, con *early stopping* en la época 265 y sin overfitting (la brecha entre train y validación es pequeña y constante). La pérdida de reconstrucción converge a $\sim 0,19$ en validación, un error mayor al del AE determinístico (0,1018). Esta diferencia es esperable ya que el término $\beta \cdot D_{KL}$ sacrifica fidelidad de reconstrucción a cambio de un espacio latente más estructurado. El comportamiento característico se ve en la curva de KL, que sube rápidamente en las primeras épocas (a medida que el encoder codifica información) y luego se estabiliza en $\sim 0,031$, reflejando el equilibrio alcanzado entre reconstruir y mantenerse cercano al prior.

Al comparar las reconstrucciones sobre las mismas 10 imágenes (Figura 6), el β -VAE produce imágenes más suaves y difuminadas que el AE, perdiendo por completo los detalles de alta frecuencia (como el estampado de la imagen 8). Nuevamente, esto no indica peor rendimiento sino el efecto de la regularización que fuerza las representaciones hacia $\mathcal{N}(0, I)$, lo que hace que el modelo priorice aprender conceptos estructurales por sobre la memorización de píxeles.






Figura 6: Comparación de reconstrucciones (de arriba a abajo): original, PCA, AE y β -VAE.

La verdadera ventaja del β -VAE se evidencia en los experimentos sobre el espacio latente

(Figura 7). En el **Experimento 1** (decodificación del promedio de los embeddings de 4 imágenes de la misma clase), el AE produce una imagen muy difusa. Esto se debe a que el AE mapea cada entrada a puntos fijos, aislados y discretos sin imponer ninguna estructura global, lo que hace que el promedio caiga en una región vacía del espacio latente que el decoder nunca aprendió a interpretar. El β -VAE, en cambio, decodifica una bota coherente, porque su espacio latente regularizado es continuo y denso, garantizando que cualquier interpolación caiga en una región válida. En el **Experimento 2** (decodificación de vectores $z \sim \mathcal{N}(0, I)$) la diferencia es aún más marcada: el AE fracasa en la tarea generativa, produciendo solo formas difusas sin sentido, mientras que el β -VAE sintetiza prendas nuevas y coherentes (remeras, pantalones, calzado). Esto confirma su capacidad generativa, ausente por completo en el AE determinístico.



(a) Experimento 1: decodificación del promedio latente de 4 imágenes de la clase 9.



(b) Experimento 2: generación a partir de ruido $z \sim \mathcal{N}(0, I)$. Fila superior: AE. Fila inferior: β -VAE.

Figura 7: Experimentos sobre los espacios latentes del AE y el β -VAE.

3.4. Clustering: selección de K

La Figura 8 resume el análisis para ambos algoritmos y espacios latentes. Del análisis de las curvas se desprenden varias conclusiones.

En primer lugar, los dos criterios no siempre coinciden, por lo que la elección de K surge de leerlos en conjunto. En el espacio de **PCA**, la ganancia marginal de K-Means se aplanan en torno a $K \approx 10$ y el Silhouette alcanza su máximo en $K = 10$ (y en $K = 9$ para GMM), señales consistentes que apuntan a unos 9–10 grupos naturales. En el espacio del **Autoencoder**, en cambio, ambos algoritmos ubican el mejor Silhouette en $K = 6$, indicando una estructura con menos grupos diferenciables.

En segundo lugar, para GMM, la *ganancia marginal* resulta demasiado ruidosa entre valores consecutivos de K como para leer un codo confiable, aun habiendo inicializado EM con los centroides de K-Means. Por ello, la decisión sobre K en GMM se apoyó principalmente en el Silhouette score. Asimismo, se observa que el Silhouette del espacio de PCA es consistentemente superior al del AE; esto no implica necesariamente un mejor clustering, ya que el

Análisis de desempeño de Clustering: Loss, Ganancia y Silhouette




Figura 8: Análisis de desempeño del clustering. Fila superior: K-Means. Fila inferior: GMM. Columnas: métrica de ajuste (inercia/NLL), ganancia marginal y Silhouette score, en función de K , para los espacios de PCA y AE.

Silhouette favorece geometrías compactas y, por construcción, PCA produce ejes decorrelacionados y ordenados por varianza que resultan más favorables a esta métrica.

Relación entre K y el número de clases. El dataset posee 10 clases reales. El espacio de PCA recupera ese número de forma aproximada ($K \approx 9-10$), mientras que el del Autoencoder tiende a comprimirlo hacia $K \approx 6$. Esta discrepancia es esperable ya que el clustering no supervisado agrupa por similitud geométrica en el espacio latente, no por la etiqueta. En consecuencia, clases visualmente parecidas (como los distintos tipos de calzado) tienden a fundirse en un mismo cluster en lugar de separarse. Por lo tanto, no debe esperarse una correspondencia exacta entre el K óptimo y el número de clases. La diferencia entre PCA y AE refleja cuánto preserva cada representación la separabilidad de esas clases solapadas.

3.5. Visualización y calidad de los clusters

A partir del análisis anterior se seleccionó $K = 10$ para K-Means y $K = 9$ para GMM sobre el espacio de PCA. La Figura 9 muestra la proyección t-SNE de las 3.000 muestras, coloreadas según las asignaciones de cada algoritmo y según las clases reales. Las Figuras 10 desglosan la composición de cada cluster por clase real, permitiendo cuantificar su tamaño y homogeneidad.

Se observa que la calidad de los clusters es heterogénea y depende de la clase que representan. Se distinguen dos grupos. Los clusters de alta homogeneidad, dominados por una única clase real: el calzado, el pantalón y la cartera forman clusters limpios y bien separados, coherentes con las islas aisladas del t-SNE por ser prendas visualmente características. Y los clusters de baja homogeneidad, donde se mezclan varias clases: las prendas de torso (remera, pulóver, vestido, abrigo y camisa) caen en clusters sin una clase claramente dominante, lo que




Figura 9: Visualización t-SNE del espacio latente de PCA. Los colores de los paneles de K-Means y GMM fueron alineados a la clase mayoritaria de cada cluster para facilitar la comparación visual con el *ground truth*.




Figura 10: Homogeneidad y tamaño de los clusters. Cada barra representa un cluster; su altura indica la cantidad de muestras (N) y su composición de colores, las clases reales que contiene.

confirma que son visualmente parecidas entre sí y que el clustering no logra separarlas (en el t-SNE ocupan una región central solapada en lugar de grupos definidos).

En cuanto al tamaño, los clusters no son uniformes: varios superan los 500 puntos, mientras que en K-Means uno queda casi sin elementos, señal de que $K = 10$ es ligeramente superior a la estructura natural de los datos. Además, algunas clases se subdividen en más de un cluster (por ejemplo, cartera aparece como mayoritaria en dos clusters distintos), lo que indica que no todos los clusters adicionales capturan una clase nueva. En conjunto, el número de clusters verdaderamente homogéneos es menor que 10, lo que explica por qué los criterios de selección de K tendían a sugerir valores más bajos que la cantidad real de clases.

4. Conclusiones

El trabajo permitió comparar dos enfoques de reducción de dimensionalidad y dos de clustering sobre Fashion-MNIST. En reconstrucción, el Autoencoder superó levemente a PCA gracias a su capacidad de modelar relaciones no lineales, aunque ambos perdieron detalles de alta frecuencia. También fue posible observar la diferencia fundamental entre un autoencoder determinístico y uno generativo. El β -VAE posee un espacio latente continuo y muestreable, capaz de generar imágenes nuevas y coherentes a partir del prior. En clustering, el espacio

latente de PCA resultó más favorable: arrojó mayores valores de Silhouette y un K óptimo ($\approx 9-10$) más cercano a las 10 clases reales, mientras que el AE tendió a $K \approx 6$. Ningún método recuperó perfectamente las 10 clases, ya que el clustering opera sobre similitud geométrica. La principal limitación fue la inestabilidad de la ganancia marginal en GMM, que obligó a apoyar la elección de K en el Silhouette.

Referencias

- [1] Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., & Lerchner, A. (2017). *β -VAE: Learning Basic Visual Concepts with a Constrained Variational Framework*. En *Proceedings of the International Conference on Learning Representations (ICLR)*.